

Predviđanje zloupotrebe kreditnih kartica

Bogdan Zdravković RA143/2023

1) Opis problema

Cilj projekta je binarna klasifikacija transakcija kreditnim karticama na legitimne i prevare. Skup podataka je izrazito neuravnotežen (samo 0,17% transakcija su označene kao prevare) što je značajno uticalo na odluke donete tokom čitavog projekta, kao što su izbor metrika, balansiranje trening skupa, itd. Cena greške je asimetrična - lažna uzbuna (false positive) šteti korisniku time što ga "iritira", ali nema pravu cenu za banku osim reputacije, dok propuštena prevara (false negative) najviše šteti banci, jer će morati da nadoknadi sredstva korisniku kojem je novac ukraden, ali šteti i korisniku zbog izazvanog stresa.

2) Struktura projekta

Projekat je organizovan u posebne skripte, od kojih svaka pokriva jednu fazu:

- pipeline.py - Glavna skripta koja pokreće ceo proces
- duplicate_analysis.py - Dijagnostika duplikata u sirovim podacima (izveštaj)
- data_preparation.py - Uklanjanje istinskih duplikata i transformacija kolone Time u Hour
- eda_analysis.py - Eksplorativna analiza i provera kvaliteta podataka (nedostajuće vrednosti, duplikati)
- train.py - Podela podataka, skaliranje, podešavanje hiperparametara, SMOTE i treniranje svih modela
- evaluate.py - Izbor modela na validacionom skupu, izbor praga po F2 metrici i finalna evaluacija na test skupu
- feature_selection.py - Selekcija broja atributa (AUPRC + 5-fold CV + pravilo 1-SE)
- app.py - Streamlit web aplikacija (deployment)

Tok pipeline-a:

- analyze_duplicates - Analiza prirode duplikata u sirovim podacima
- prepare_data - Uklanjanje istinskih duplikata i transformacija kolone Time u Hour
- run_eda - Provera kvaliteta i grafici
- train_pipeline - Podela (70/15/15), RandomizedSearchCV sa RobustScaler i SMOTE unutar foldova, RobustScaler i SMOTE na celom trening skupu, trening svih modela
- select_best_model_on_validation - Izbor najboljeg modela na validacionom skupu
- optimize_threshold - Podešavanje praga odluke na validacionom skupu
- exhaustive_feature_selection - Biranje što manjeg broja atributa na trening skupu tako da su rezultati najbliži modelu treniranom sa svih 30 atributa
- evaluate_models - Finalne metrike, baseline model, analiza grešaka na test skupu

Projekat ima 2 grane - *main* (koristi svih 30 atributa) i *18_atributa* (koristi 18 najznačajnijih atributa, izabranih pravilom 1-SE).

3) Skup podataka

Korišćen je [Credit Card Fraud Detection](#) skup podataka sa Kaggle platforme. U originalnom obliku sadrži 284.807 transakcija evropskih korisnika kreditnih kartica tokom 2 dana. Nakon uklanjanja 1.081 duplikata (isti po svim atributima) ostaje 283.726 transakcija, od čega su 473 označene kao prevare (0,167%).

Svaka transakcija opisana je sledećim atributima:

- V1 do V28 - **PCA transformisane** originalne karakteristike. Zbog poverljivosti bankovnih podataka, originalni atributi nisu javno dostupni, već samo njihova projekcija na glavne komponente. Zbog PCA transformacije koja je unapred odrađena, ovi atributi su već standardizovani.
- Amount - Iznos transakcije.
- Time - Vreme u sekundama od prve transakcije u skupu.
- Class - Izlazna oznaka (0 - legitimna, 1 - prevara).

4) Priprema podataka

Pre uklanjanja, skripta duplicate_analysis proverava da li su duplikati možda signal prevare. Među 1.081 duplikata stopa prevara je 1,73%, ali u apsolutnim brojevima to je samo 19 prevarantskih kopija. Pošto brisanje uklanja samo suvišne kopije (i zadržava jedinstvenih 473), a zadržavanje identičnih redova uz nasumičnu podelu vodi u curenje podataka, odluka je da se duplikati ipak uklone.

Uklanjanje identičnih duplikata

U sirovim podacima postoji 1.081 redova koji su identični duplikati, što znači da su im svi atributi sa istim međusobnim vrednostima kao neki drugi red. Pošto je praktično nemoguće da se 2 transakcije dese u istoj sekundi i da imaju identične vrednosti V1-V28, uklonjene su iz skupa podataka, pre svih ostalih koraka, kako bi model što manje pamtio i zapravo učio obrazac. Bitno je da je ovo odrađeno pre transformacije iz Time u Hour, zato što nakon te transformacije transakcija može biti duplikat i biti legitimna (npr. automatska mesečna pretplata nekog servisa poput Netflix-a). Takođe je bitno ukloniti ih da prilikom podele podataka na train/validation/test isti podatak ne bude u train i test skupu, što bi naduvavalo rezultate jer je model već video primer.

Napomena: Treniranje modela je prvobitno bilo odrađeno bez uklanjanja duplikata i njihovo brisanje je smanjilo metrike. Ovo direktno potvrđuje da duplikati mogu lažno naduvati rezultate.

Transformacija Time -> Hour

Pošto kolona Time predstavlja samo kontinuirani tok sekundi, ona modelu neće doprineti, ili će čak otežati, da generalizuje naučeno, jer specifičan podatak poput "sekunda 142.214" ne pruža upotrebljiv kontekst za obradu novih transakcija. Zato je transformisana u Hour (sat u danu, u opsegu od 0 do 23), što ima više smisla za generalizaciju znanja (npr. prevare se dešavaju u specifičnom delu dana). Ova transformacija je deterministička jer se računa za svaki red zasebno (pa ne može doći do curenja podataka) i zato je bezbedna pre podele.

Formula za konverziju: $\text{Hour} = (\text{Time} // 3600) \% 24$

Sprečavanje curenja podataka

- Podela na skupove je *prvi* korak u treniranju modela, pre skaliranja i SMOTE-a. Da su podaci prvo obrađeni pa podeljeni, statistika (medijana, IQR) test skupa bi procurila u proces treniranja.
- Podela je izvršena na 70% trening, 15% validacija i 15% test, uz stratifikaciju klasa. Stratifikacija omogućava da se svakom skupu dodeli odgovarajući procenat obe klase, kako se ne bi desilo da u nekom od skupova nema klase prevare, a da neki skup sadrži skoro sve prevare.
- Skaliranje (pomoću RobustScaler) primenjeno je isključivo na koloni Amount. RobustScaler koristi medijanu i interkvartalni raspon (razliku vrednosti ispod kojih se nalazi 75% i 25% svih vrednosti skupa) pa je otporniji na ekstremne vrednosti (kojih u koloni Amount ima).
- Da statistika skaliranja ne bi procurila, skaler se tokom unakrsne validacije (podešavanje hiperparametara, selekcija atributa) fituje iznova unutar svakog folda - samo na trening delu folda, pa medijana i IQR validacionog dela ne učestvuju u skaliranju. Za finalne modele skaler se fituje na celom trening skupu, a iste mere se zatim primenjuju na validacioni i test skup
- V1 - V28 se ne skaliraju zato što su već PCA transformisane vrednosti, dakle standardizovane su.
- SMOTE se primenjuje isključivo na trening podatke - tokom validacije unutar svakog folda (samo na trening delu folda), a za finalne modele na celom trening skupu. Validacioni i test skup ostaju u prirodnoj, nebalansiranoj raspodeli.
- Test skup se koristi samo jednom, na kraju, kada su podešavanje hiperparametara i trening već završeni.

5) Balansiranje klasa

Na skupu sa samo 0,167% prevara, model bi bez balansiranja imao pristrasnost da uvek predviđa legitimne transakcije, čime bi postizao tačnost od 99,833% (zato se ova metrika i ne koristi), a ne bi imao nikakvu korisnu primenu. Zbog toga su generisani sintetički podaci prevara korišćenjem SMOTE (Synthetic Minority Over-sampling Technique), koja ne duplira postojeće prevare, već interpolacijom između susednih primera generiše nove, sintetičke podatke, dok manjinska klasa ne dostigne broj većinske.

SMOTE je primenjena 2 nezavisna puta:

- Prilikom podešavanja hiperparametara, korišćena je na trening delu foldova, da podaci ne bi procureli u validacioni deo.
- Prilikom treniranja modela primenjeno je samo na trening skupu, a validacioni i testni skupovi su ostali netaknuti, jer se u realnosti model sreće sa takvim podacima i to je ono gde su njegovi rezultati bitni.

6) Eksplorativna analiza (EDA)


Pre treniranja provereno je stanje podataka:

Ukupno transakcija:	283.726
Legitimne (klasa 0):	283.253
Prevare (klasa 1):	473 (0.167%)
Nedostajuće vrednosti:	0
Duplikati (redovi):	2.804

Pošto skup nema nedostajućih vrednosti, nije bilo potrebe za izbacivanjem ili dodavanjem redova. Duplikati koji se ovde nalaze *nisu* rezultat lošeg uklanjanja duplikata od ranije, već su nastali transformacijom kolone Time u Hour, pa su transakcije sa istim vrednostima ostalih atributa ovom transformacijom (ako im se i Hour poklapa) postali duplikati. Ovi duplikati se zadržavaju namerno jer mogu predstavljati automatske transakcije koje se izvršavaju u određeno vreme (npr. subskripcije, stipendije, penzije, itd.)


Raspodela klasa:

Prikazano logaritamskom skalom, jer na linearnoj skali klasa prevara se ne bi videla, što dodatno ilustruje ekstremnu nebalansiranost.



Matrica korelacije:

Zbog PCA transformacije, atributi V1-V28 su međusobno nekorelisani (osobina PCA transformacije). Po apsolutnoj vrednosti korelacije sa ciljnom promenljivom class izdvaja se nekoliko atributa (V17, V14, V12, V10, V16) koji će se kasnije pojaviti na vrhu liste važnosti iz RandomForest-a.



7) Odabir i treniranje modela

- Logistička regresija
 - Jednostavan, brz i interpretabilan model
 - “Prirodna donja granica” među ostalim modelima
 - Linearan - gubi na složenim granicama odluke
- Stablo odlučivanja
 - Potpuno interpretabilno (pravi pravila koja su lako razumljiva)
 - Hvata i nelinearne veze, ali je sklon overfitting-u
- Random Forest (100 i 150 stabala)
 - Ansambl nezavisnih stabala (bagging i slučajan izbor atributa) koji usrednjavanjem ispravlja preprilagođavanje pojedinačnih stabala
 - Dobar za skupove sa mnogo podataka i velikom dimenzionalnošću
 - Daje ugrađenu meru važnosti atributa
 - Urađen sa različitim brojem stabala radi poređenja uticaja veličine ansambla
- XGBoost
 - Gradient boosting koji stabla gradi sekvencijalno, gde svako novo stablo ispravlja greške prethodnog
 - Ima ugrađenu L2 regularizaciju

Modeli koji su bili u opticaju, ali nisu izabrani:

- SVM - Prevelika složenost treniranja, pa bi na skupu podataka od 400.000 (nakon SMOTE) podataka trening trajao predugo
- KNN - Sporost predikcije (poredi se sa celim trening skupom) i loš pri velikim dimenzionalnostima
- Isolation Forest i Local Outlier Factor - Tehnike nenadgledanog učenja, pa na skupu podataka koji je potpuno označen nemaju smisla

8) Podešavanje hiperparametara

Hiperparametri su birani RandomizedSearchCV sa 5-fold unakrsnom validacijom na trening skupu, optimizovano po AUPRC (Area Under Precision-Recall Curve). RandomizedSearchCV deli trening skup na 5 delova, od kojih se 4 koristi za trening (na koje su primenjeni RobustScaler i SMOTE - oba unutar foldova kako ne bi došlo do curenja u validacioni deo), a 1 za validaciju. Za neke od modela, koji imaju mali prostor pretrage (logistička regresija i Random Forest) broj iteracija pokriva sve kombinacije, pa je pretraga efektivno GridSearch. Mana GridSearch-a je što je sporiji jer se testiraju apsolutno sve kombinacije. RandomizedSearchCV ne garantuje najbolju vrednost, jer se kombinacije koje će biti isprobane biraju nasumično, ali je zato brži. Takođe, za izbor hiperparametara XGBoost modela korišćeno je 50 stabala, a u finalnom treningu 100.

Pretraživani su hiperparametri koji najdirektnije utiču na preprilagođavanje:

- Logistička regresija
 - C [0,001; 0,01; 0,1; 1; 10; 100] - Jačina regularizacije
- Stablo odlučivanja
 - max_depth [5; 10; 15; 20; None]
 - min_samples_leaf [1; 2; 4; 8] - Minimalan broj transakcija koja moraju ostati u listu kako bi stablo donelo odluku
 - criterion [gini; entropy] - Pomoć pri odlučivanju postavljanja pitanja
- RandomForest
 - n_estimators [100; 150] - Podešeni ručno i nisu deo pretrage
 - max_depth [10; 20; None]
 - max_features [sqrt, log2] - Broj atributa po podeli (dekorelacija stabala)
- XGBoost
 - learning_rate [0,01; 0,05; 0,1; 0,3]
 - max_depth [3; 5; 7]
 - subsample [0,7; 0,8; 1] - Procenat redova (transakcija) trening skupa koji se daje svakom stablu
 - colsample_bytree [0,7; 0,8; 1] - Procenat kolona (atributa) trening skupa koji se daje svakom stablu

Rezultati pretrage:

--- LogisticRegression ---

Najbolji parametri: {'C': 100}

Najbolji AUPRC (CV): 0.7368

--- DecisionTree ---

Najbolji parametri: {'min_samples_leaf': 8, 'max_depth': 10, 'criterion': 'entropy'}

Najbolji AUPRC (CV): 0.5865

--- RandomForest_100 ---

Najbolji parametri: {'max_features': 'log2', 'max_depth': None}

Najbolji AUPRC (CV): 0.8426

--- RandomForest_150 ---

Najbolji parametri: {'max_features': 'log2', 'max_depth': None}

Najbolji AUPRC (CV): 0.8430

--- XGBoost ---

Najbolji parametri: {'subsample': 0.8, 'max_depth': 7, 'learning_rate': 0.3, 'colsample_bytree': 1.0}

Najbolji AUPRC (CV): 0.8355

9) Analiza rezultata

Izbor metrika

Accuracy (tačnost) se u ovom projektu ne koristi. Model koji bi svaku transakciju proglasi legitimnom imao bi tačnost skoro 100% i nula uhvaćenih prevara. Na ovako neuravnoteženom skupu tačnost praktično samo meri veličinu većinske klase.


Korišćene su metrike koje se fokusiraju na manjinsku klasu, uz naglasak da je propuštena prevara (false negative) za banku skuplja od lažnog alarma (false positive).

- Odziv (Recall) - Udeo uhvaćenih prevara. Računa se kao $TP/(TP+FN)$
- Preciznost (Precision) - Udeo pravih prevara među uzbunama. Meri koliko sistem "davi" legitimne korisnike. Računa se kao $TP/(TP+FP)$
- F1 - Harmonijska sredina odziva i preciznosti. Računa se kao $2 * Precision * Recall / (Precision + Recall)$
- F2 - Kao F1, ali daje 4 puta veću važnost odzivu nego preciznosti (propuštena prevara je skuplja od lažne uzbune). Koristi se za izbor praga uzbune.
- ROC AUC - Sposobnost modela da uspešno razlikuje prevare od legitimnih transakcija, širom svih mogućih pragova klasifikacije. Za neuravnotežene podatke može biti previše optimističan, jer FP uglavnom čine mali deo negativne klase.
- AUPRC - Primarna metrika. Fokusirana na manjinsku klasu i daje najrealniju sliku performansi modela na nebalansiranim podacima, mereći balans između uspešno uhvaćenih prevara i lažnih uzbuna.

Baseline


Nasumičan klasifikator (DummyClassifier) koji predviđa po raspodeli klasa. Teorijski AUPRC nasumičnog klasifikatora je jednak stopi prevara u test skupu, ali je ovde izmereni AUPRC 0,0008, što je i dalje istog reda veličine kao 0,0017.







Rezultati na testnom skupu:



=== ZBIRNA TABELA (sve metrike, test skup, prag 0.5) ===

Model	Prec	Recall	F1	F2	ROC-AUC	AUPRC
DecisionTree	0.0375	0.7746	0.0716	0.1571	0.8673	0.6401
LogisticRegression	0.0516	0.8592	0.0974	0.2080	0.9630	0.6796
RandomForest_100	0.9032	0.7887	0.8421	0.8092	0.9745	0.8143
RandomForest_150	0.9016	0.7746	0.8333	0.7971	0.9723	0.8153
XGBoost	0.7671	0.7887	0.7778	0.7843	0.9594	0.8109





Zanimljivo zapažanje je da logistička regresija ima najveću vrednost odziva, ali očajnu preciznost, dok ansambli žrtvuju malo vrednosti odziva za mnogo bolju preciznost, što je za realan sistem daleko upotrebljivije.

Izbor modela:

Najbolji model bira se isključivo na validacionom skupu, dok se testni skup ne koristi ni pri treniranju, ni pri izboru modela, ni pri izboru praga, već samo jednom, za finalni izveštaj.

```
=== IZBOR MODELA NA VALIDACIONOM SKUPU (po AUPRC) ===  
Model se bira ovde; finalni rezultat se prijavljuje na test skupu.
```

```
RandomForest_100: AUPRC = 0.8560  
RandomForest_150: AUPRC = 0.8558  
XGBoost: AUPRC = 0.8504  
DecisionTree: AUPRC = 0.7354  
LogisticRegression: AUPRC = 0.7353
```

```
Izabrani model: RandomForest_100 (AUPRC = 0.8560)
```

Podešavanje praga:

Podrazumevani prag od 0.5 nije nužno optimalan, pogotovo kada je cena FN i FP asimetrična. Zato je na validacionom skupu tražen prag koji maksimizuje F2 metriku. F2 daje odzivu 4 puta veću težinu od preciznosti, čime se dodatno potkrepljuje činjenica da je propuštena prevara skuplja od lažne uzbune.

```
=== PODEŠAVANJE PRAGA ODLUKE (F2, na validaciji) ===  
F2 naglašava odziv 4x – propuštena prevara je skuplja od lažne uzbune.
```

Model	Opt.prag	F2(0.5)	F2(opt)
DecisionTree	0.95	0.1769	0.7056
LogisticRegression	0.95	0.2175	0.5439
RandomForest_100	0.50	0.8596	0.8596
RandomForest_150	0.50	0.8596	0.8596
XGBoost	0.84	0.8403	0.8406

Potvrda praga na test skupu:

Prag je biran po F2 meri, na validacionom skupu, i kasnije primenjen na testnom skupu.

=== EFEKAT PRAGA NA TEST SKUPU (0.5 vs F2-optimalni prag) ===

Model	Prag	Recall	Prec	F1	F2	FN	FP
DecisionTree	0.50	0.7746	0.0375	0.0716	0.1571	16	1411
DecisionTree	0.95*	0.7465	0.3869	0.5096	0.6295	18	84
LogisticRegression	0.50	0.8592	0.0516	0.0974	0.2080	10	1121
LogisticRegression	0.95*	0.8169	0.2222	0.3494	0.5321	13	203
RandomForest_100	0.50	0.7887	0.9032	0.8421	0.8092	15	6
RandomForest_100	0.50*	0.7887	0.9032	0.8421	0.8092	15	6
RandomForest_150	0.50	0.7746	0.9016	0.8333	0.7971	16	6
RandomForest_150	0.50*	0.7746	0.9016	0.8333	0.7971	16	6
XGBoost	0.50	0.7887	0.7671	0.7778	0.7843	15	17
XGBoost	0.84*	0.7606	0.9000	0.8244	0.7849	17	6

Pokazuje se da je F2-optimalni prag za slabije modele viši od 0.5 (npr. 0.95): dizanjem praga drastično se smanjuje broj lažnih uzbuna (FP) i raste preciznost, uz tek mali pad odziva (nešto više FN) — pa F2 raste. Kod jakih ansambala (RandomForest) F2-optimalni prag je već 0.5, pa ostaje nepromenjen.

Analiza grešaka:

=== ANALIZA GREŠAKA (po iznosu) ===

FN = propuštene prevare | FP = lažne uzbune | TP = uhvaćene prevare

Model	FN	FP	TP	Iznos FN	Iznos TP
DecisionTree	16	1411	55	144.08	172.24
LogisticRegression	10	1121	61	227.68	155.77
RandomForest_100	15	6	56	274.55	136.79
RandomForest_150	16	6	55	272.39	134.92
XGBoost	15	17	56	152.64	169.45

- Izabrani RandomForest_100 propušta prevare čiji je prosečan iznos dvostruko veći od prosečnog iznosa uhvaćenih - sistematski mu promiču skuplje prevare. Uz svega 15


promašaja, prosek je osetljiv na pojedinačne velike transakcije, ali to je nešto što sama vrednost metrika ne govori i zato je ovakva analiza bitna.

- Logistička regresija uhvati najviše prevara (61/71), ali po cenu 1.121 lažne uzbune, što znači da bi blokirala karticu otprilike svakom 38. legitimnom kupcu, što je u produkciji neupotrebljivo.
- RandomForest_100 postiže najbolji kompromis, samo 6 lažnih uzbuna na 42.488 legitimnih transakcija, uz 56/71 uhvaćenu prevaru.

10) Odabir najznačajnijih atributa

Cilj ove analize bio je odgovoriti na pitanje - Da li je za predikciju stvarno potrebno svih 30 atributa ili je dovoljan mali podskup? Atributi se prvo rangiraju po važnosti iz istreniranog RandomForest modela (samo na osnovu podataka iz trening skupa). Zatim se za svaki top k podskup ($k=1, 2, 3 \dots 30$) meri AUPRC kroz 5-fold stratifikovanu unakrsnu validaciju na trening skupu (RobustScaler i SMOTE unutar svakog folda), a test skup se ne dira. Broj atributa bira se pravilom 1 standardne greške (1-SE): najmanji k čiji CV AUPRC nije lošiji od vrednosti (najbolji AUPRC-1*SE). Time se bira najjednostavniji model koji je izuzetno sličan najboljem.

Najbolji prosečni AUPRC je bio sa $k=24$, ali pravilo 1-SE bira $k=18$ atributa: V14, V4, V12, V17, V10, V11, V16, V3, V2, V7, V9, V21, V18, V8, Hour, V5, V19, V28.



Ovih 18 atributa se koristi na posebnoj grani *18_atributa* gde se isti modeli treniraju na manjem skupu podataka. Zanimljivo zapažanje je da kolona Amount uopšte ne spada u 18 najznačajnijih atributa.

11) Poređenje grana

Da bi se proverilo da li 18 izabranih atributa zaista dobro zamenjuje svih 30, na grani *18_atributa* su svi modeli ponovo istrenirani samo na tih 18 atributa, uz identičan ostatak postupka (ista podela, SMOTE, prag, itd.). Skripta *poredjenje_rezultata/uporedi.py* poredi dve grane na testnom skupu, po svakoj metrici.

=== AUPRC (primarna metrika) po modelu ===

DecisionTree	main=0.6401	18=0.6054	$\Delta=-0.0347$	-> main
LogisticRegression	main=0.6796	18=0.6231	$\Delta=-0.0565$	-> main
RandomForest_100	main=0.8143	18=0.8115	$\Delta=-0.0028$	-> main
RandomForest_150	main=0.8153	18=0.8115	$\Delta=-0.0038$	-> main
XGBoost	main=0.8109	18=0.8141	$\Delta=+0.0032$	-> 18_atributa

Kompletna analiza se nalazi u dokumentu poredjenje_rezultata/poredjenje.txt, a slika predstavlja poređenje samo po AUPRC (glavnu metriku).

Kod ansambl metoda razlika rezultata po AUPRC je praktično zanemarljiva, što znači da smanjenje broja atributa sa 30 na 18 skoro da ne šteti kvalitetu rezultata (kod XGBoost, grana sa 18 atributa je čak za nijansu i bolja). Jednostavni modeli (stablo odluke i logistička regresija) su dosta osetljiviji na izbacivanje atributa i tu main zadržava prednost. Glavni benefit 18 atributa je jednostavnost (manja dimenzija, brže treniranje, lakša interpretacija) uz gotovo isti rezultat.

12) Deployment

Izrađena je Streamlit aplikacija koja demonstrira sistem u realnom scenariju. Omogućeni su izbor modela, kao i praga osetljivosti. Aplikacija radi sa stvarnim vrednostima iz test skupa i korisniku ispisuje stvarni (neskalirani) iznos transackije u evrima (Amout). Za svaki model se automatski postavlja njegov F2-optimalni prag (iz models/best_thresholds.json), uz zadržan klizač za ručno podešavanje.