

Predviđanje zloupotrebe kreditnih kartica

Bogdan Zdravković RA143/2023

1) Opis problema

Cilj projekta je binarna klasifikacija transakcija kreditnim karticama na legitimne i prevare. Skup podataka je izrazito neuravnotežen (samo 0,17% transakcija su označene kao prevare) što je značajno uticalo na odluke donete tokom čitavog projekta, kao što su izbor metrika, balansiranje trening skupa, itd. Cena greške je asimetrična - lažna uzbuna (false positive) šteti korisniku time što ga "iritira", ali nema pravu cenu za banku osim reputacije, dok propuštena prevara (false negative) najviše šteti banci, jer će mora nadoknaditi sredstva korisniku kojem je novac ukraden, ali šteti i korisniku zbog izazvanog stresa.

2) Struktura projekta

Projekat je organizovan u posebne skripte, od kojih svaka pokriva jednu fazu:

- pipeline.py - Glavna skripta koja pokreće ceo proces
- data_preparation.py - Uklanjanje istinskih duplikata i transformacija kolone Time u Hour
- eda_analysis.py - Eksplorativna analiza i provera kvaliteta podataka (nedostajuće vrednosti, duplikati)
- train.py - Podela podataka, skaliranje, podešavanje hiperparametara, SMOTE i treniranje svih modela
- evaluate.py - Izbor modela na validacionom skupu, izbor praga po F2 metrici i finalna evaluacija na test skupu
- feature_selection.py - Analiza važnosti atributa (nije deo glavnog pipeline-a, već se vrši zasebno)
- app.py - Streamlit web aplikacija (deployment)

Tok pipeline-a:

- prepare_data - Uklanjanje istinskih duplikata i transformacija kolone Time u Hour
- run_eda - Provera kvaliteta i grafici
- train_pipeline - Podela (70/15/15), skaliranje (fit samo na trening skupu), RandomizedSearchCV sa SMOTE u foldovima, SMOTE na trening skupu, treniranje svih modela
- select_best_model_on_validation - Izbor najboljeg modela na validacionom skupu
- optimize_threshold - Podešavanje praga odluke na validacionom skupu
- evaluate_models - Finalne metrike, baseline model, analiza grešaka na test skupu

Projekat ima 2 grane - *main* (koristi svih 30 atributa) i *24_atributa* (koristi 24 najznačajnija atributa). *Napomena - proveriti sekciju 10)*

3) Skup podataka

Korišćen je [Credit Card Fraud Detection](#) skup podataka sa Kaggle platforme. U originalnom obliku sadrži 284.807 transakcija evropskih korisnika kreditnih kartica tokom 2 dana. Nakon uklanjanja 1.081 duplikata (isti po svim atributima) ostaje 283.726 transakcija, od čega su 473 označene kao prevare (0,167%).

Svaka transakcija opisana je sledećim atributima:

- V1 do V28 - **PCA transformisane** originalne karakteristike. Zbog poverljivosti bankovnih podataka, originalni atributi nisu javno dostupni, već samo njihova projekcija na glavne komponente. Zbog PCA transformacije koja je unapred odrađena, ovi atributi su već standardizovani.
- Amount - Iznos transakcije.
- Time - Vreme u sekundama od prve transakcije u skupu.
- Class - Izlazna oznaka (0 - legitimna, 1 - prevara).

4) Priprema podataka

Uklanjanje identičnih duplikata

U sirovim podacima postoji 1.081 redova koji su identični duplikati, što znači da su im svi atributi sa istim međusobnim vrednostima kao neki drugi red. Pošto je praktično nemoguće da se 2 transakcije dese u istoj sekundi i da imaju identične vrednosti V1-V28, uklonjene su iz skupa podataka, pre svih ostalih koraka, kako bi model što manje pamtio i zapravo učio obrazac. Bitno je da je ovo odrađeno pre transformacije iz Time u Hour, zato što nakon te transformacije transakcija može imati biti duplikat i biti legitimna (npr. automatska mesečna pretplata nekog servisa poput Netflix). Takođe je bitno ukloniti ih da prilikom podele podataka na train/validation/test isti podatak ne bude u train i test skupu, što bi naduvavalo rezultate jer je model već video primer.

Napomena: Treniranje modela je prvobitno bilo odrađeno bez uklanjanja duplikata i njihovo brisanje je smanjilo metrike. Ovo direktno potvrđuje da duplikati mogu lažno naduvati rezultate.

Transformacija Time -> Hour

Pošto kolona Time predstavlja samo kontinuirani tok sekundi, ona modelu neće doprineti, ili će čak otežati, da generalizuje naučeno, jer specifičan podatak poput "sekunda 142.214" ne pruža upotrebljiv kontekst za obradu novih transakcija. Zato je transformisana u Hour (sat u danu, u opsegu od 0 do 23), što ima više smisla za generalizaciju znanja (npr. prevare se dešavaju u specifičnom delu dana). Ova transformacija je deterministička jer se računa za svaki red zasebno (pa ne može doći do curenja podataka) i zato je bezbedna pre podele.

Formula za konverziju: $\text{Hour} = (\text{Time} // 3600) \% 24$

Sprečavanje curenja podataka

- Podela na skupove je *prvi* korak u treniranju modela, pre skaliranja i SMOTE. Da su podaci prvo obrađeni pa podeljeni, statistika (medijana, IQR) test skupa bi procurili u proces treniranja.
- Podela je izvršena na 70% trening, 15% validacija i 15% test, uz stratifikaciju klasa. Stratifikacija omogućava da se svakom skupu dodeli odgovarajući procenat obe klase, kako se ne bi desilo da u nekom od skupova nema klase prevare, a da neki skup sadrži skoro sve prevare.
- Skaliranje (pomoću RobustScaler) primenjeno je na koloni Amount. Fitovanje (računanje medijane i IQR) rađeno je samo na trening skupu i te mere su kasnije primenjene na validacioni i test skup. RobustScaler koristi medijanu i interkvartilni raspon (razliku

vrednosti ispod kojih se nalazi 75% i 25% svih vrednosti skupa) pa je otporniji na ekstremne vrednosti (koje kolona Amount i sadrži).

- V1 - V28 se ne skaliraju zato što su već PCA transformisane vrednosti, dakle standardizovani su.
- SMOTE je odvojeno primenjen prilikom biranja hiperparametara i prilikom treniranja modela.
- Test skup se koristi samo jednom, na kraju, kada su podešavanje hiperparametara i trening već završeni.

5) Balansiranje klasa

Na skupu sa samo 0,167% prevara, model bi bez balansiranja imao pristrastnost da uvek predviđa legitimne transakcije, čime bi postizao tačnost od 99,833% (zato se ova metrika i ne koristi), a ne bi imao nikakvu korisnu primenu. Zbog toga su generisani sintetički podaci prevara korišćenjem SMOTE (Synthetic Minority Over-sampling Technique), koja ne duplira postojeće prevare, već interpolacijom između susednih primera generiše nove, sintetičke podatke, dok manjinska klasa ne dostigne broj većinske.

SMOTE je primenjena 2 nezavisna puta:

- Prilikom podešavanja hiperparametara, korišćena je na trening delu foldova, da podaci ne bi procureli u validacioni deo.
- Prilikom treniranja modela primenjeno je samo na trening skupu, a validacioni i testni skupovi su ostali netaknuti, jer se u realnosti model sreće sa takvim podacima i to je ono gde su njegovi rezultati bitni.

6) Eksplorativna analiza (EDA)


Pre treniranja provereno je stanje podataka:

Ukupno transakcija:	283.726
Legitimne (klasa 0):	283.253
Prevare (klasa 1):	473 (0.167%)
Nedostajuće vrednosti:	0
Duplikati (redovi):	2.804

Pošto skup nema nedostajućih vrednosti, nije bilo potrebe za izbacivanjem ili dodavanjem redova. Duplikati koji se ovde nalaze *nisu* rezultat lošeg uklanjanja duplikata od ranije, već su nastali transformacijom kolone Time u Hour, pa su transakcije sa istim vrednostima ostalih atributa ovom transformacijom (ako im se i Hour poklapa) postali duplikati. Ovi duplikati se zadržavaju namerno jer mogu predstavljati automatske transakcije koje se izvršavaju u određeno vreme (npr. subskripcije, stipendije, penzije, itd.)


Raspodela klasa:

Prikazano logaritamskom skalom, jer na linearnoj skali klasa prevara se ne bi videla, što dodatno ilustruje ekstremnu nebalansiranost.



Matrica korelacije:

Zbog PCA transformacije, atributi V1-V28 su međusobno nekorelisani (osobina PCA transformacije). Po apsolutnoj vrednosti korelacije sa ciljnom promenljivom class izdvaja se nekoliko atributa (V17, V14, V12, V10, V16) koji će se kasnije pojaviti na vrhu liste važnosti iz RandomForest-a.



7) Odabir i treniranje modela

- Logistička regresija
 - Jednostavan, brz i interpretabilan model
 - “Prirodna donja granica” među ostalim modelima
 - Linearan - gubi na složenim granicama odluke
- Stablo odlučivanja
 - Potpuno interpretabilno (pravi pravila koja su lako razumljiva)
 - Hvata i nelinearne veze, ali je sklon overfitting-u
- Random Forest (100 i 150 stabala)
 - Ansambl nezavisnih stabala (bagging i slučajan izbor atributa) koji usrednjavanjem ispravlja preprilagođavanje pojedinačnih stabala
 - Dobar za skupove sa mnogo podataka i velikom dimenzionalnošću
 - Daje ugrađenu meru važnosti atributa
 - Urađen sa različitim brojem stabala radi poređenja uticaja veličine ansambla
- XGBoost
 - Gradient boosting koji stabla gradi sekvencijalno, gde svako novo stablo ispravlja greške prethodnog
 - Ima ugrađenu L2 regularizaciju

Modeli koji su bili u opticaju, ali nisu izabrani:

- SVM - Prevelika složenost treniranja, pa bi na skupu podataka od 400.000 (nakon SMOTE) podataka trening trajao predugo
- KNN - Sporost predikcije (poredi se sa celim trening skupom) i loš pri velikim dimenzionalnostima
- Isolation Forest i Local Outlier Factor - Tehnike nenadgledanog učenja, pa na skupu podataka koji je potpuno označen nemaju smisla

8) Podešavanje hiperparametara

Hiperparametri su birani RandomizedSearchCV sa 5-fold unakrsnom validacijom na trening skupu, optimizovano po AUPRC (Area Under Precision-Recall Curve). RandomizedSearchCV deli trening skup na 5 delova, od kojih se 4 koristi za trening (na koje je primenjen SMOTE), a 1 za validaciju. Za neke od modela (logistička regresija i Random Forest) RandomizedSearchCV je korišćen kao GridSearch zbog toga što nemaju mnogo hiperparametara koji se biraju. Mana GridSearch je što je sporiji jer se testiraju apsolutno sve kombinacije. RandomizedSearchCV ne garantuje najbolju vrednost, jer se kombinacije koje će biti isprobane biraju nasumično, ali je zato brži. Takođe, za izbor hiperparametara XGBoost modela korišćeno je 50 stabala, a u finalnom treningu 100.

Pretraživani su hiperparametri koji najdirektnije utiču na prilagođavanje:

- Logistička regresija
 - C [0,001; 0,01; 0,1; 1; 10; 100] - Jačina regularizacije
- Stablo odlučivanja
 - max_depth [5; 10; 15; 20; None]
 - min_samples_leaf [1; 2; 4; 8] - Minimalan broj transakcija koja moraju ostati u listu kako bi stablo donelo odluku
 - criterion [gini; entropy] - Pomoć pri odlučivanju postavljanja pitanja
- RandomForest
 - n_estimators [100; 150] - Podešeni ručno i nisu deo pretrage
 - max_depth [10; 20; None]
 - max_features [sqrt, log2] - Broj atributa po podeli (dekorelacija stabala)
- XGBoost
 - learning_rate [0,01; 0,05; 0,1; 0,3]
 - max_depth [3; 5; 7]
 - subsample [0,7; 0,8; 1] - Procenat redova (transakcija) trening skupa koji se daje svakom stablu
 - colsample_bytree [0,7; 0,8; 1] - Procenat kolona (atributa) trening skupa koji se daje svakom stablu

Rezultati pretrage:

--- LogisticRegression ---

Najbolji parametri: {'C': 100}

Najbolji AUPRC (CV): 0.7368

--- DecisionTree ---

Najbolji parametri: {'min_samples_leaf': 8, 'max_depth': 10, 'criterion': 'entropy'}

Najbolji AUPRC (CV): 0.5870

--- RandomForest_100 ---

Najbolji parametri: {'max_features': 'log2', 'max_depth': None}

Najbolji AUPRC (CV): 0.8379

--- RandomForest_150 ---

Najbolji parametri: {'max_features': 'sqrt', 'max_depth': None}

Najbolji AUPRC (CV): 0.8383

--- XGBoost ---

Najbolji parametri: {'subsample': 0.8, 'max_depth': 7, 'learning_rate': 0.3, 'colsample_bytree': 1.0}

Najbolji AUPRC (CV): 0.8433

9) Analiza rezultata

Izbor metrika

Accuracy (tačnost) se u ovom projektu ne koristi. Model koji bi svaku transakciju proglasio legitimnom imao bi tačnost skoro 100% i nula uhvaćenih prevara. Na ovako neuravnoteženom skupu tačnost praktično samo meri veličinu većinske klase.


Korišćene su metrike koje se fokusiraju na manjinsku klasu, uz naglasak da je propuštena prevara (false negative) za banku skuplja od lažnog alarma (false positive).



- Odziv (Recall) - Udeo uhvaćenih prevara. Računa se kao $TP/(TP+FN)$
- Preciznost (Precision) - Udeo pravih prevara među uzbunama. Meri koliko sistem "davi" legitimne korisnike. Računa se kao $TP/(TP+FP)$
- F1 - Harmonijska sredina odziva i preciznosti. Računa se kao $2*Precision*Recall/(Precision+Recall)$
- ROC AUC - Sposobnost modela da uspešno razlikuje prevare od legitimnih transakcija, širom svih mogućih pragova klasifikacije. Za neuravnotežene podatke može biti previše optimističan, jer FP uglavnom čine mali deo negativne klase.
- AUPRC - Primarna metrika. Fokusirana na manjinsku klasu i daje najrealniju sliku performansi modela na nebalansiranim podacima, mereći balans između uspešno uhvaćenih prevara i lažnih uzbuna.






Baseline

Nasumičan klasifikator (DummyClassifier) koji predviđa po raspodeli klasa. Teorijski AUPRC nasumičnog klasifikatora je jednak stopi prevara u test skupu, ali je ovde izmereni AUPRC 0,0008, što je i dalje istog reda veličine kao 0,0017.

Rezultati na testnom skupu:







Zanimljivo zapažanje je da logistička regresija ima najveću vrednost odziva, ali očajnu preciznost, dok ansamblu žrtvuju malo preciznosti za mnogo bolju preciznost, što je za realan sistem daleko upotrebljivije.

Izbor modela:

Najbolji model bira se isključivo na validacionom skupu, dok se testni skup ne koristi ni pri treniranju, ni pri izboru modela, ni pri izboru praga, već samo jednom, za finalni izveštaj.

Model	AUPRC (validacija)
RandomForest_100	0.8560 ← izabran
RandomForest_150	0.8550
XGBoost	0.8504
Stablo odlučivanja	0.7354
Logistička regresija	0.7353

Podešavanje praga:

Podrazumevani prag od 0.5 nije nužno optimalan, pogotovo kada je cena FN i FP asimetrična. Zato je na validacionom skupu tražen prag koji maksimizuje F2 metriku. F2 daje odzivu 4 puta veću težinu od preciznosti, čime se dodatno potkrepljuje činjenica da je propuštena prevara skuplja od lažne uzbune.

Model	Optimalan prag	F2 (prag 0.5)	F2 (opt. prag)
Stablo odlučivanja	0.95	0.1769	0.7056
Logistička regresija	0.95	0.2175	0.5439
Random Forest (100)	0.50	0.8596	0.8596
Random Forest (150)	0.52	0.8596	0.8621
XGBoost	0.84	0.8403	0.8406

Analiza grešaka:

=== ANALIZA GREŠAKA (po iznosu) ===					
Model	FN	FP	TP	Avg_FN_Amt	Avg_TP_Amt
RandomForest_100.p	15	6	56	41.17	85.95
LogisticRegression	10	1121	61	41.84	82.17
DecisionTree.pkl	16	1411	55	48.78	84.55
RandomForest_150.p	15	7	56	48.31	84.04
XGBoost.pkl	15	17	56	38.99	86.53

- Izabrani RandomForest_100 propušta prevare čiji je prosečan iznos dvostruko manji od prosečnog iznosa uhvaćenih. Ovo znači da model u praksi promašuje jeftiniju vrstu greške. Ovo je nešto što AUPRC ne vidi i zato je bitno odraditi ovakvu analizu.
- Logistička regresija uhvati najviše prevara (61/71), ali po cenu 1.121 lažne uzbune, što znači da bi blokirala karticu otprilike svakom 38. legitimnom kupcu, što je u produkcijineupotrebljivo.
- RandomForest_100 postiže najbolji kompromis, samo 6 lažnih uzbuna na 42.488 legitimnih transakcija, uz 56/71 uhvaćenu prevaru.

10) Odabir najznačajnijih atributa

```
MESTO #1 | Korišćeno 8 atributa
Odziv (Recall): 0.8592
Preciznost: 0.7262
Korišćene kolone: V14, V4, V12, V17, V10, V11, V16, V3
-----
MESTO #2 | Korišćeno 9 atributa
Odziv (Recall): 0.8592
Preciznost: 0.7176
Korišćene kolone: V14, V4, V12, V17, V10, V11, V16, V3, V2
-----
MESTO #3 | Korišćeno 7 atributa
Odziv (Recall): 0.8592
Preciznost: 0.6703
Korišćene kolone: V14, V4, V12, V17, V10, V11, V16
-----
MESTO #4 | Korišćeno 3 atributa
Odziv (Recall): 0.8592
Preciznost: 0.1912
Korišćene kolone: V14, V4, V12
-----
MESTO #5 | Korišćeno 28 atributa
Odziv (Recall): 0.8451
Preciznost: 0.9375
Korišćene kolone: V14, V4, V12, V17, V10, V11, V16, V3, V2, V7, V9, V21, V18, V8, Hour, V5, V19, V28, V20, V27, V1, V6, V26, Scaled_Amount, V13, V24, V15, V23
-----
```

Nakon brisanja duplikata u početnim fazama projekta, broj najznačajnijih grana i koje su to grane se značajno promenio sa 24 na 8. Zbog ograničenja vremenskog roka nisam bio u mogućnosti da ponovo treniram modele na 8 najbitnijih atributa i da nakon toga uporedim rezultate sa main granom gde je trenirano sa svih 30.

11) Deployment

Izrađena je Streamlit aplikacija koja demonstrira sistem u realnom scenariju. Omogućeni su izbor modela, kao i praga osetljivosti. Aplikacija radi sa stvarnim vrednostima iz testnog skupa i korisniku ispisuje neskalinu vrednost atributa Ammount.

12) Budući rad i poboljšanja

Ono što bi rad dodatno poboljšalo bilo bi poređenje rezultata kada se modeli treniraju na svih 30 atributa i na najboljih 8. Usled kasnije odluke da se duplikati brišu, promenio se ceo koncept rezultata i toga koji su atributi najvažniji. Potrebno je odraditi kompletan trening i analizu sa 8 atributa.

Još jedno od poboljšanja je da se više ni jedna skripta ne pokreće ručno, već da postoji jedna skripta koja bi od početka do kraja pozivala sve ostale skripte za preprocesiranje, trening i analizu. U trenutnoj strukturi, pipeline.py ne pokreće analizu najbitnijih atributa i analize greške, što je dodatno otežalo i odužilo izradu projekta, a i same dokumentacije. Zbog ove greške propala je čitava ideja upoređivanja modela treniranih na različitim brojevima atributa.